

# UNIVERSIDAD DE GUADALAJARA



## CENTRO UNIVERSITARIO DE CIENCIAS EXACTAS E INGENIERÍAS

### Sistemas Inteligentes IV

#### Actividad 4. Regresión no lineal

Pacheco Quintero Marco Antonio      213535019

28 de marzo de 2021

Semestre 2021A

Sección D01


## Objetivo

- Para la parte 1 y 2, realizar un programa en Python para aplicar una regresión no lineal a los datos de los archivos adjuntos. Utilizar las herramientas sklearn para los modelos de regresión.
- Para cada caso utilizar las métricas de coeficiente  $R^2$  para demostrar que el entrenamiento tiene una buena generalización, es decir aplicar la métrica tanto a los datos de entrenamiento como a los datos de generalización y comparar. Además, utilizar los siguientes modelos de regresión no lineal para cada caso:
  - Árboles de decisión
  - K vecinos más cercanos
  - Máquinas de soporte vectorial
  - Modelo Kernel Ridge
  - Perceptrón Multicapa

## Resultados

### Parte 1

- Para el archivo adjunto [“df\\_regresion\\_lineal\\_1.csv”](#) se muestran a continuación los mejores resultados obtenidos para cada modelo de regresión no lineal.
  - Árboles de decisión




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{\text{entrenamiento}} = 0.9966830566003961$$

$$R^2_{\text{generalización}} = 0.9912231719708637$$

- K vecinos más cercanos




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{entrenamiento} = 0.990224038318564$$

$$R^2_{generalización} = 0.9901684920697457$$

- Máquinas de soporte vectorial




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{entrenamiento} = 0.9903586884911487$$

$$R^2_{generalización} = 0.9905319556135425$$

- Modelo Kernel Ridge




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{entrenamiento} = 0.9906871991311287$$

$$R^2_{generalización} = 0.9907638536261403$$

- Perceptrón Multicapa




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{entrenamiento} = 0.9911012913408913$$

$$R^2_{generalización} = 0.9922620159426936$$

- Para el archivo adjunto [“df\\_regresion\\_lineal\\_2.csv”](#) se muestran a continuación los mejores resultados obtenidos para cada modelo de regresión no lineal.

- Árboles de decisión




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{\text{entrenamiento}} = 0.9803594663660876$$

$$R^2_{\text{generalización}} = 0.9859844817230015$$

- K vecinos más cercanos




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{\text{entrenamiento}} = 0.9853043762636129$$

$$R^2_{\text{generalización}} = 0.9882795312773415$$

- Máquinas de soporte vectorial




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{entrenamiento} = 0.991699282243735$$

$$R^2_{generalización} = 0.993941633619911$$

- Modelo Kernel Ridge




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{entrenamiento} = 0.990565131300977$$

$$R^2_{generalización} = 0.9905022860802658$$

- Perceptrón Multicapa

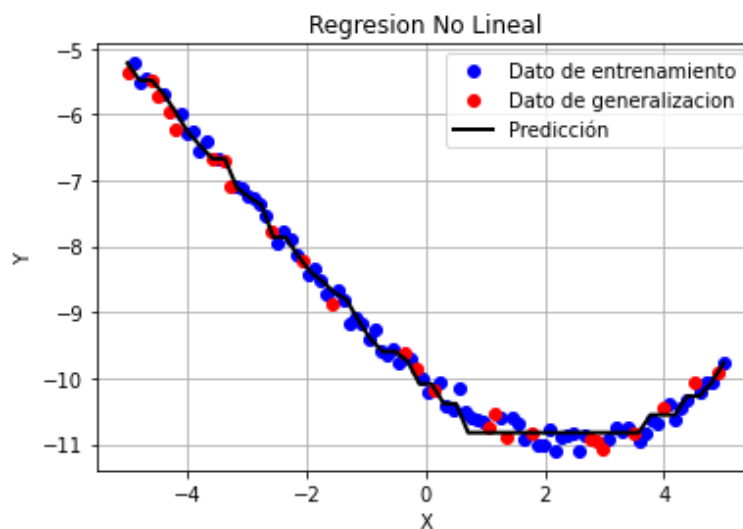


Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{\text{entrenamiento}} = 0.9848557965018866$$

$$R^2_{\text{generalización}} = 0.9857953439105567$$

- Para el archivo adjunto [“df\\_regresion\\_lineal\\_3.csv”](#) se muestran a continuación los mejores resultados obtenidos para cada modelo de regresión no lineal.
  - Árboles de decisión




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{\text{entrenamiento}} = 0.9966621504214498$$

$$R^2_{\text{generalización}} = 0.9952021752693148$$

- K vecinos más cercanos




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{\text{entrenamiento}} = 0.9955497132057783$$

$$R^2_{\text{generalización}} = 0.995211733978862$$

- Máquinas de soporte vectorial




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{\text{entrenamiento}} = 0.9960965948931696$$

$$R^2_{\text{generalización}} = 0.9967822081657817$$



- Modelo Kernel Ridge

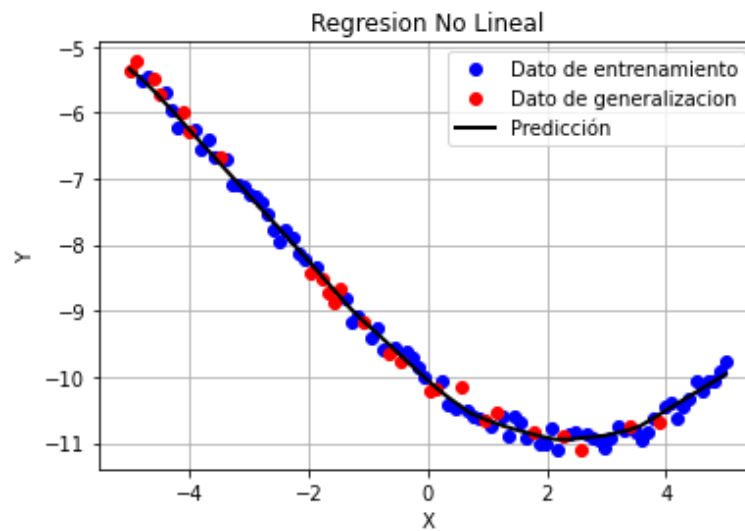


Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{entrenamiento} = 0.9959822111263891$$

$$R^2_{generalización} = 0.9968959256735346$$

- Perceptrón Multicapa




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{entrenamiento} = 0.995794530075644$$

$$R^2_{generalización} = 0.9957606986822023$$

## Parte 2

- Para el archivo adjunto “df\_regresion\_lineal\_temp.csv” se muestran a continuación los mejores resultados obtenidos para cada modelo de regresión no lineal.
  - Árboles de decisión




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{\text{entrenamiento}} = 0.9959387056933656$$

$$R^2_{\text{generalización}} = 0.9959875585103156$$

- K vecinos más cercanos

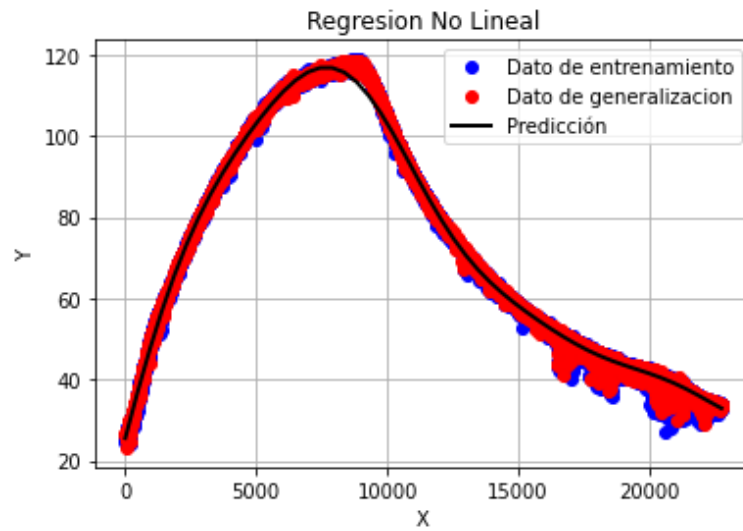


Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{\text{entrenamiento}} = 0.9991096895540626$$

$$R^2_{\text{generalización}} = 0.9991064981788736$$

- Máquinas de soporte vectorial




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{entrenamiento} = 0.9974456244787996$$

$$R^2_{generalización} = 0.9977135870597328$$

- Modelo Kernel Ridge




Los resultados de las métricas de coeficiente  $R^2$  fueron:

$$R^2_{entrenamiento} = 0.9979591020680619$$

$$R^2_{generalización} = 0.9980437505807429$$

- Perceptrón Multicapa

Los resultados de las métricas de coeficiente  $R^2$  fueron:



$$R^2_{\text{entrenamiento}} = 0.9989307938079555$$

$$R^2_{\text{generalización}} = 0.9989345742706945$$

## Conclusión

Al realizar la actividad en la parte 1 se notó que el modelo de regresión de árboles de decisiones fue el más difícil de configurar en cuanto a sus parámetros con el fin de obtener una buena generalización. Mientras que el modelo que menos ajustes necesito fue el modelo de máquinas de soporte vectorial (SVR).

En cuanto a la parte 2 fue más fácil encontrar los parámetros correctos en todos los modelos con el fin de tener una buena generalización, esto tal vez por la mayor cantidad de datos que tenemos de muestra. Para este conjunto de datos los modelos SVR, kernel Ridge y del perceptrón multicapa tardaron más en su ejecución. Pero su ventaja fue que dieron resultados muy buenos en comparación a los primeros modelos vistos.